# Claim Management System — Logic Optimization & Operability Enhancement

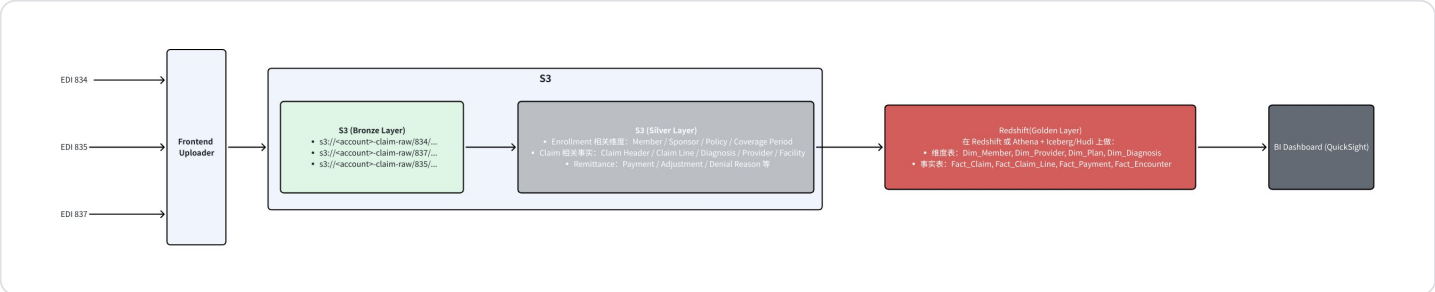


## 1. 目标重申（用一句话对齐）

> 在 AWS 上搭一个 **湖仓一体（Lakehouse）** 的 *Claim Data 平台*，
>
> - 上游拿到的是 EDI 834 / 835 / 837（或已转换/可转换为 CSV）
> - **S3 作为唯一原始存储层（Raw Layer）**，原始只能是 CSV
> - 满足合规（HIPAA：加密、访问控制、审计、数据血缘）
> - 下游既能做 **OLAP 分析 / BI**，也能支撑后续 **实时/批处理风控 & 报表**

下面按“分层 + 组件”来规划。

---

## 2. 总体架构视图（从左到右）

### 1.1 数据流主线（业务视角）

1. **外部/上游系统**
   - Policy Admin / Claim System / Clearing House 提供：
     - EDI 834（Enrollment）
     - EDI 837（Claims）
     - EDI 835（Remittance）
   - 形式可以是一个我自建的前端，可选文件上传格式（支持x12/csv),
2. **Ingestion & Landing（落地 + 安全）**
   - 统一通过 **Ingestion Bucket (S3 Raw)** 落地：
     - `s3://<account>-claim-raw/834/...`

        - `s3://<account>-claim-raw/837/...`
        - `s3://<account>-claim-raw/835/...`
    - 要求：
        - 对于CSV: 直接存储到raw
        - 对于X12:
            - 上游上传 **X12** 到 `claim-edi-archive`（WORM + 合规保留策略）。
            - S3 Event / Step Functions 触发 **解析 Lambda / Glue Job**：
            - 读取 X12 → 按你定义好的 mapping 转成一到多个 CSV（member / claim_header / claim_line / payment …）
            - 解析结果 CSV 写入 `claim-lake/raw/...`，这里才是 **数据湖的 raw 层**。
3. **标准化 & 清洗（Bronze → Silver）**
    - 使用 Glue / EMR / Lambda 将原始 CSV 转成 **结构化表**：
        - Enrollment 相关维度：Member / Sponsor / Policy / Coverage Period
        - Claim 相关事实：Claim Header / Claim Line / Diagnosis / Provider / Facility
        - Remittance：Payment / Adjustment / Denial Reason 等
    - 输出到 **S3 Silver 层**（仍然是 CSV 或 Parquet，建议 Parquet + 分区）。
4. **数仓建模（Silver → Gold）**
    - 在 **Redshift 或 Athena + Iceberg/Hudi** 上做：
        - 维度表：Dim_Member, Dim_Provider, Dim_Plan, Dim_Diagnosis
        - 事实表：Fact_Claim, Fact_Claim_Line, Fact_Payment, Fact_Encounter
    - 形成一个 **可分析的星型模型**，支撑：
        - Claim Cost 分析
        - Provider Performance
        - Fraud & Overutilization 检测
        - Enrollment & Retention 分析
5. **消费层（BI & API）**
    - BI：QuickSight（SPICE）看 dashboard（按 payer/provider/member 分析 claim）。
    - Ad-hoc 分析：Athena / Redshift Query Editor。
    - 下游服务：通过 API Gateway + Lambda 或 Redshift Data API 暴露查询结果（比如给 Risk Engine / Care Management 系统）。

---

## 3. 分层设计（Lakehouse 三层 + Catalog）

你刚好要求“数湖一体”，我们可以按**经典 Bronze / Silver / Gold + Catalog** 来设计。

### 2.1 Bronze（Raw / Landing Layer —— 必须是 S3 + CSV）

**目的：合规 + 不可篡改 + 数湖入口**

**存储：**

- `S3: claim-raw-bucket`
- Key 命名示例：
  - `raw/834/year=2025/month=11/day=21/source=clearinghouse/file_20251121_001.csv`
  - `raw/837/year=2025/...`
  - `raw/835/year=2025/...`

**要求：**

1. **安全性：**
   - 开启 **S3 Versioning + MFA Delete**（防止误删/篡改）。
   - 开启默认 **S3 加密（SSE-KMS）**，KMS CMK 单独 Key（例如 `kms-key-claim-raw`）。
   - **Bucket Policy** 严控：只允许特定 VPC Endpoint / 角色访问。
2. **审计 & 血缘：**
   - 使用 **CloudTrail + S3 Access Logs** 跟踪访问。
   - 每个文件落地时写一条 **元数据记录**（Glue Table 或 DynamoDB）：
     - file_name, file_type(834/837/835), source_system, ingest_time, checksum, record_count, uploader

> 这一层你可以理解为“合规黑盒”：只进不改，只读解，强加密，可审计。

---

### 2.2 Silver（Standardized / Clean Layer）

**目的：从“行级 CSV”变成“业务实体级的结构化表”**

**存储：**

- 专门一个 S3 bucket 或同 bucket 不同 prefix：
  - `s3://claim-lake/silver/834_member/`
  - `s3://claim-lake/silver/837_claim_header/`
  - `s3://claim-lake/silver/837_claim_line/`

- `s3://claim-lake/silver/835_payment/`

**特点：**

- Schema 已经和**业务实体**对齐：
  - 834 → Member, Coverage, Enrollment Event
  - 837 → Claim, Claim Line, Diagnosis, Service Provider
  - 835 → Payment, Adjustment, Remittance Advice
- 数据做了基础清洗：
  - 类型转换（日期、金额、枚举字段）
  - 去重、基础校验（必填、PK/FK 合法性）
  - 记录解析错误到 **Error Table / Error Path**（比如 `silver/_error/...`）

**计算引擎：**

- 批处理：
  - **AWS Glue Job (Spark)**：批量每天/每小时跑，解析 CSV → 结构化表。
- 实时/准实时：
  - 如果将来需要 near real-time，可以考虑 Kinesis + Lambda 先入 raw，然后 Glue Streaming/EMR Streaming 转入 Silver。

---

## 2.3 Gold（Warehouse / Serving Layer）

1. **Redshift (推荐做 Enterprise Data Warehouse)**
   - 把 Silver（S3 上的 Parquet）通过 Glue Catalog 映射到 Redshift 外部表或者直接 COPY 进内部表。
   - 建模为典型星型：
     - Dimensions:
       - `dim_member`
       - `dim_provider`
       - `dim_plan`
       - `dim_diagnosis`
       - `dim_facility`
     - Facts:
       - `fact_claim`（一行一 claim）
       - `fact_claim_line`（一行一行项目）

- `fact_payment`（从 835）
- `fact_eligibility`（可从 834 enrollment 状态推）

---

## 4. 数据目录 & 元数据：Glue Data Catalog

要做“数湖一体”，**Catalog 是中枢神经**。

### 3.1 Catalog 作用

1. 记录所有 **数据库/表/字段/分区** 信息（Raw/Silver/Gold）。
2. 让 Athena / Glue / Redshift Spectrum / EMR 用同一套 schema。
3. 后续可以接 **Data Governance 工具**（标签、PII 标注、访问控制）。

### 3.2 拆分建议

在 Glue Catalog 中建立几个 Database：

- `claim_raw_db`
  - `tbl_834_raw_csv`
  - `tbl_837_raw_csv`
  - `tbl_835_raw_csv`
- `claim_silver_db`
  - `tbl_member`
  - `tbl_claim_header`
  - `tbl_claim_line`
  - `tbl_payment`
- `claim_gold_db`
  - `dim_member`
  - `dim_provider`
  - `dim_plan`
  - `fact_claim`
  - `fact_payment`

---

## 5. 合规与安全设计（HIPAA 角度）

### 4.1 存储安全（静态）

- 所有 S3 bucket 开启 **SSE-KMS**，使用独立的 CMK（raw/silver/gold 可共用或分开）。
- Redshift 使用 **KMS 加密**，且在 VPC 私网中。
- 对含 PHI 的字段打标签（比如 `phi_pii=true`），将来可配合 Column Masking / Row-Level Security。

### 4.2 访问控制（访问中）

- 全面使用 **IAM Role + ABAC/Tag-Based Policy**：
  - 比如 `role-claim-analyst` 只能访问 `gold` 层的某些表。
  - `role-claim-etl` 才能访问 `raw/silver` + KMS key decrypt。
- 使用 **Lake Formation**（如果走 S3 Lake）做细粒度权限（表、列、行级）。

### 4.3 审计 & 监控

- **CloudTrail**：记录所有数据平面/控制平面操作。
- **CloudWatch + CloudWatch Metric/Log**：
  - Glue Job 失败/成功次数
  - ETL 延迟、文件处理量
  - S3 访问错误/拒绝统计
- 可以搭一个简单的 **“Data Pipeline Health Dashboard”**（QuickSight 或 CloudWatch Dashboard）。

---

## 6. Ingestion 层设计（文件如何进入 S3 Raw）

虽然你现在问题主要在数据中心/湖仓本身，但 **入口设计** 对合规也很关键：

1. **SFTP / FTPS**：
   - 使用 **AWS Transfer Family(SFTP)** → 直接写到 S3 Raw Bucket。
2. **API Upload**：
   - API Gateway + Lambda → 验证签名/格式 → 写入 S3 Raw。
3. **内网对接**：
   - 如果是同一 VPC 内其他系统，可以通过 VPC Endpoint 直接 putObject 到 S3。

> 所有入口统一一个原则：**只写入 CSV 到 Raw**，禁止绕过。

---

## 7. 处理 & 调度（Workflow Orchestration）

为了系统可管理，需要一个统一调度：

- **Step Functions / Managed Airflow (MWAA)** 二选一：
  - 典型流程（以日批为例）：
    i. 监听新文件（S3 Event → SQS → StepFunctions/Airflow Trigger）。
    ii. 任务 1：调用 Glue Job 解析 834/837/835 → 写入 Silver。
    iii. 任务 2：数据质量检查（记录数对比、必填字段检查，异常报警）。
    iv. 任务 3：将 Silver 数据加载/物化到 Gold（Redshift/ Iceberg）。
    v. 任务 4：刷新 QuickSight SPICE dataset 或触发通知。

先直接按你这套架构，把“**会用到什么技术栈**”拆成三块讲：

1. **AWS Services 全家桶（按分层对应一下）**
2. **Version Control / IaC / DevOps 技术栈**
3. **文件上传网站的技术选型（前后端 + 在 AWS 上怎么落地）**

---

## 8. 这里会用到哪些 AWS Services?

### 1）存储 & 数据湖（Raw / Silver / Gold）

- **Amazon S3**
  - Raw：`claim-raw-bucket`
  - Silver / Gold：`claim-lake-bucket`
  - 配置：
    - Versioning +（可选）Object Lock / WORM
    - SSE-KMS 加密
    - S3 Access Logs（记录访问行为）
- **AWS KMS**
  - KMS CMK：
    - `kms-claim-raw`
    - `kms-claim-silver-gold`
  - 用于 S3 + Redshift + Glue Job 的加密解密

> 如果你要做长期归档 / 法规保留：

- **S3 Glacier / Glacier Deep Archive**
  - 存历史 X12 原文、老的 Raw CSV 归档

---

## 2）Ingestion & API 入口

- **AWS Transfer Family (SFTP)**
  - 让 Clearing House / 上游系统通过 SFTP 直接丢文件到 S3 Raw。
- **Amazon API Gateway**
  - 做“文件上传网站”的后端入口（REST/HTTP API），前端调用 API 拿 pre-signed URL 或直接 POST。
- **AWS Lambda**
  - 文件到达 S3 → 触发 Lambda：
    - 校验文件名/格式/元数据
    - 调用解析逻辑（或者丢到 SQS/Kinesis）
- **Amazon SQS**
  - S3 Event → SQS → Step Functions / Lambda 做异步处理、重试、DLQ。
- （可选）**Amazon Kinesis Data Streams / Firehose**
  - 如果后面有 near real-time claim event 流式场景，可以把事件打入 Kinesis。

---

## 3）计算 & ETL & Lakehouse

- **AWS Glue**
  - Glue Crawler：建 Raw / Silver 表的 schema（注册到 Glue Data Catalog）。
  - Glue Job（Spark）：
    - 解析 CSV → 标准化成 Member / Claim / Payment 等实体（Silver）。
    - 从 Silver 聚合 / 转换 → Gold 表（给 Redshift/Catalog）。
  - Glue Workflow：可当简单的 pipeline orchestration。
- （可选）**Amazon EMR / EMR Serverless**
  - 如果后面有大规模批处理、机器学习、复杂 Spark Job，用 EMR 更灵活。
- **Amazon Athena**
  - 直接查 S3 上的 Raw / Silver / Gold 表（通过 Glue Catalog）。
  - 给数据科学 / ad-hoc 查询用。

## 4）数据仓库 / Gold 层 Serving

- **Amazon Redshift（推荐用 Redshift Serverless）**
  - 建 star schema：
    - `dim_member / dim_provider / dim_plan / dim_diagnosis / dim_facility`
    - `fact_claim / fact_claim_line / fact_payment / fact_eligibility`
  - 集成方式：
    - Spectrum 外部表直接扫 S3（Silver / Gold Parquet）
    - 或定期 COPY / MERGE 到 Redshift 内部表（性能更好）

---

## 5）Catalog & 权限治理

- **AWS Glue Data Catalog**
  - Database：
    - `claim_raw_db` / `claim_silver_db` / `claim_gold_db`
- **AWS Lake Formation**
  - 表/列级权限控制（谁能查 PHI、谁只能看汇总）。
  - 再往上可以做 Tag-based access（例如：`phi=true` 的列只有特定角色可见）。

---

## 6）安全、合规 & 审计

- **AWS IAM**
  - Role 设计：
    - `role-claim-ingestion` 只负责一个方向的写入 Raw
    - `role-claim-etl` 负责 Glue / Lambda / KMS 解密等
    - `role-claim-analyst` 只看 Gold / 部分 Silver
- **AWS CloudTrail**
  - 记录所有控制平面 & 数据平面操作（谁创建了 bucket、谁查了什么表）。
- **Amazon CloudWatch**
  - 监控 Glue Job / Lambda / Step Functions 的运行情况。
  - 告警：延迟、失败率、异常访问。

- （可选）**Amazon Macie**
  - 自动扫描 S3，识别 PII/PHI，帮你验证合规风险。

---

### 7）BI & 报表 & Dashboard

- **Amazon QuickSight**
  - 直接连：
    - Athena（查 S3 Gold / Redshift）
    - Redshift
  - 开 SPICE 做加速，给业务用户看 dashboard。

---

### 8）网络 & 入口安全

- **Amazon VPC + VPC Endpoint**
  - 确保 Glue / Lambda / Redshift 访问 S3 走内网。
- **Amazon CloudFront**
  - 前端静态网站（React 构建结果） + API Gateway 的边缘加速。
- **AWS WAF**
  - 给 API Gateway / CloudFront 加 web 防火墙（防 SQL 注入、常见攻击）。
- **Amazon Route 53**
  - 域名 + DNS + ACM 证书（HTTPS）。

---

## 9. Version Control / IaC / DevOps 技术栈

你这套平台可以完全按“**代码化的平台**”来做：

### 1）Version Control

- **Git + GitLab / GitHub**
  - Repo 分组建议：
    - `infra-claim-platform`：只放 Terraform / CDK / CloudFormation
    - `etl-claim-glue-jobs`：Glue Job / Spark / PySpark 代码
    - `api-claim-upload-portal`：前端 + 后端代码
  - Branch 策略：

- `main` / `dev` / feature branches
- 合并到 `main` 触发 prod 环境部署

---

## 2）Infra as Code（IaC）

- **Terraform**（你刚提到的，强烈推荐）
  - 模块划分：
    - `network`：VPC, Subnet, Security Group, VPC Endpoint
    - `security`：IAM Role, KMS, CloudTrail, Config
    - `data-lake`：S3 Raw/Silver/Gold, Glue Catalog, Lake Formation
    - `warehouse`：Redshift, Workgroup, Namespace
    - `app`：API Gateway, Lambda, Cognito, CloudFront, Route 53
  - Backend：
    - S3 + DynamoDB 做 Terraform Remote State & State Lock。
- （可选）**AWS CDK**
  - 用 TypeScript/Python 写复杂资源（比如 CloudFront + S3 + Lambda@Edge 的组合）。
  - 也可以只用 Terraform，就不用 CDK 了，看你团队习惯。

---

## 3）CI/CD

- **GitHub Actions / GitLab CI/CD**
  - Pipeline 示例：
    i. **Infra Pipeline**（针对 `infra-claim-platform` repo）
      - `terraform fmt` / `terraform validate`
      - `terraform plan`（在 MR/PR 上做 review）
      - `terraform apply`（合并到 main 时自动 apply 到 prod）

    ii. **ETL Pipeline**（针对 Glue Job 代码）
      - 单元测试（PyTest）
      - 打包 Zip/Whl 上传到 S3 / ECR
      - 调用 `aws glue update-job` / `create-job` API

    iii. **App Pipeline（文件上传网站）**

- 前端：`npm test` / `npm build` → 把 build 结果 sync 到 S3 + 触发 CloudFront Invalidation
- 后端：打包 Lambda / Docker 镜像 → 部署到 Lambda / ECS

---

### 4）配置 & Secrets 管理

- **AWS Systems Manager Parameter Store**
  - 存：环境配置（例如 S3 bucket name, 业务开关）。
- **AWS Secrets Manager**
  - 存：数据库密码、第三方 API Key 等敏感信息。
- 使用 IAM Role + KMS 加密访问这些参数。

---

### 5）数据质量 & 测试（可选但强烈推荐）

- **Great Expectations / Soda Core**
  - 对 Silver → Gold 过程加 data quality check，例如：
    - record count 对比
    - PK 不为空
    - 金额范围合理
  - 通过 Glue Job / Lambda 调用。

---

## 10. 文件上传网站应该用什么技术?

你这个“文件上传网站”主要需求是：

- 用户（上游系统或 internal ops）登录
- 上传 EDI X12 或 CSV
- 写入 S3 Raw（带元数据）
- 触发后续 ETL

推荐一个 **偏工程化 + Serverless** 的组合：

### 架构概览

**前端：React SPA → S3 + CloudFront**
**后端：API Gateway + Lambda (Python/FastAPI 或 Node.js/NestJS 风格)**
**鉴权：Cognito**

**存储：S3 + DynamoDB（存元数据）**

---

## 1）前端技术栈

- **React + TypeScript**
  - UI 框架：Ant Design / MUI / Chakra UI 随便挑一个。
  - 功能：
    - 登录（Cognito Hosted UI 或 SDK）
    - 文件选择 / 拖拽上传
    - 调用后端 API 拿 pre-signed URL
    - 展示上传进度、历史上传记录
- 部署：
  - 使用 `npm build` → 将 build 静态资源部署到 S3
  - 使用 CloudFront 作为 CDN + HTTPS 入口

---

## 2）后端（API 层）

- **Amazon API Gateway**
  - 提供 REST API：
    - `POST /upload-request`：生成 pre-signed URL + 记录 metadata
    - `GET /uploads`：查询历史文件
- **AWS Lambda**
  - 运行语言建议：
    - Python（FastAPI + Mangum / 纯 handler，和你 ETL 生态统一）
    - 或 Node.js + NestJS / Express
  - 主要逻辑：
    - 校验调用者身份（通过 Cognito JWT）
    - 生成 S3 pre-signed URL（指定 bucket、key、文件大小限制、Content-Type）
    - 把一条上传记录写入 **DynamoDB**：
      - `file_id, file_name, file_type, uploader, upload_url_expire_at, status`

- 上传完成后可以用 S3 Event 通知 Lambda，更新 DynamoDB 中 status = `INGESTED`，再丢消息到 SQS/Step Functions 继续 ETL。

---

### 3）鉴权 & 用户管理

- **Amazon Cognito**
  - User Pool：管理用户登录 / 注册 / MFA。
  - Identity Pool（可选）：映射到不同 IAM Role，控制他们可以上传哪些 payer 的数据。
- 前端用 Cognito SDK 获取 ID Token / Access Token，带入 API Gateway。

---

### 4）部署 & 运维

- 前端：
  - CI：GitHub Actions / GitLab CI
  - 自动：
    - build → sync to S3 → CloudFront Invalidation
- 后端：
  - CI：
    - 单测（PyTest / Jest）
    - 打包 Lambda zip
    - `aws cloudformation deploy` 或 Terraform 自动更新 Lambda + API Gateway
- 监控：
  - CloudWatch Logs：记录 API 请求、Lambda 错误
  - CloudWatch Alarm：错误率、延迟、5xx 异常等

---

## 如果你要一句“总结式 stack 介绍”给简历/文档用

你可以这样写一版简短 summary（英文）：

> Built a HIPAA-compliant claim Lakehouse on AWS using S3 (raw/silver/gold), Glue, Athena, and Redshift Serverless, governed by Glue Data Catalog + Lake Formation, with end-to-end ingestion orchestrated by S3 Events, Lambda, Step Functions, and SQS.
> Infrastructure is fully managed as code via Terraform and GitLab CI/CD, while a React + API Gateway + Lambda + Cognito upload portal enables external partners to securely submit X12/CSV claim feeds directly into the raw layer.

如果你愿意，我可以下一步帮你：

- 把上面这些技术栈梳成一张“**组件清单表**”（列：功能模块 / AWS Service / 非 AWS 技术 / 备注），
- 或者直接帮你写一段“项目架构说明书”的「技术栈章节」。